

ÉTUDE BIBLIOGRAPHIQUE

Comptage intelligent des personnes par caméra

Vision par ordinateur · Détection · Suivi multi-objets

Mémoire de fin d'études — Master STIC · 2025–2026

Encadreurs : Dr RAJONIRINA Solofanja Jeannie & Dr HDR ANDRIANAJAINA Todizara

Table des matières

1. Détection d'objets : YOLO, SSD, Faster R-CNN
2. Suivi multi-objets : SORT, DeepSORT, ByteTrack
3. Méthodes de comptage de personnes
4. Datasets & benchmarks
5. Métriques d'évaluation
6. Synthèse comparative & choix technologiques
7. Références bibliographiques

Chapitre 1 — Détection d'objets

1.1 Introduction à la détection d'objets

La détection d'objets est une tâche fondamentale de la vision par ordinateur qui consiste à localiser et classifier simultanément des instances d'objets dans une image. Contrairement à la simple classification d'image, la détection produit des boîtes englobantes (bounding boxes) précises autour de chaque objet détecté, accompagnées d'un score de confiance et d'une étiquette de classe. Dans le cadre du comptage de personnes, la qualité de cette détection conditionne directement la précision du comptage final.

1.2 Faster R-CNN

Faster R-CNN (Region-based Convolutional Neural Network), proposé par Ren et al. (2015), est l'un des détecteurs d'objets les plus influents de la littérature. Il s'articule autour d'une architecture en deux étapes :

- **Region Proposal Network (RPN)** : un sous-réseau qui parcourt les cartes de caractéristiques extraites par un backbone (VGG, ResNet) et propose des zones candidates susceptibles de contenir un objet, associées à un score d'objectivité.
- **Réseau de classification et de régression** : il affine les coordonnées des boîtes proposées et attribue une classe à chaque région candidate.

Points clés : Très haute précision (mAP élevé sur COCO), mais vitesse limitée à ~5-7 FPS sur GPU standard, ce qui le rend inadapté au traitement temps réel. Référence : Ren S. et al., *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*, NeurIPS 2015.

1.3 SSD — Single Shot MultiBox Detector

Liu et al. (2016) proposent SSD comme une alternative plus rapide à Faster R-CNN, en éliminant l'étape séparée de proposition de régions. SSD effectue la détection et la classification en une seule passe du réseau, en analysant l'image à plusieurs échelles grâce à des cartes de caractéristiques de résolutions différentes :

- Les **couches profondes** détectent les grands objets (contexte global).
- Les **couches intermédiaires** détectent les objets de taille moyenne.
- Les **premières couches** capturent les détails fins pour les petits objets.

Points clés : ~30-45 FPS sur GPU, bon compromis vitesse/précision, mais moins performant sur les petits objets et les scènes très denses. Référence : Liu W. et al., *SSD: Single Shot MultiBox Detector*, ECCV 2016.

1.4 YOLO — You Only Look Once

YOLO, introduit par Redmon et al. (2016), représente une rupture paradigmatique dans la détection d'objets. L'image est divisée en une grille $S \times S$ de cellules. Pour chaque cellule, le réseau prédit simultanément plusieurs boîtes englobantes et les probabilités de classe correspondantes, en une seule inférence réseau. Cette approche permet d'atteindre des performances temps réel remarquables.

Depuis la version originale, YOLO a connu de nombreuses évolutions majeures :

YOLOv1	Redmon et al.	2016	Concept one-shot, grille $S \times S$
YOLOv3	Redmon, Farhadi	2018	Multi-scale, DarkNet-53
YOLOv5	Ultralytics	2020	PyTorch natif, CSPNet backbone
YOLOv8	Ultralytics	2023	Anchor-free, tâches multiples
YOLOv11	Ultralytics	2024	Architecture améliorée, plus léger

Recommandation pour ce projet : YOLOv8 (Ultralytics, 2023) est le choix optimal. Il offre une API Python simple, des modèles pré-entraînés sur COCO (incluant la classe *person*), et une intégration native de ByteTrack. Un modèle YOLOv8n (nano) tourne à >60 FPS sur GPU et >15 FPS en CPU, adapté à un déploiement léger.

1.5 Comparaison des détecteurs

Architecture	2 étapes (RPN)	1 étape multi-scale	1 étape anchor-free
Vitesse (GPU)	~5-7 FPS	~30-45 FPS	~60-120 FPS
Précision (mAP)	Très haute	Haute	Très haute
Petits objets	Bonne	Moyenne	Bonne
Facilité d'usage	Complexe	Moyenne	Très simple
Temps réel	Non	Oui (limité)	Oui
Recommandé ici	Non	Possible	✓ Oui

Chapitre 2 — Suivi multi-objets (Tracking)

2.1 Problématique du suivi multi-objets

Le suivi multi-objets (Multi-Object Tracking, MOT) consiste à maintenir l'identité de chaque individu détecté à travers les images successives d'une vidéo. Sans tracking, un système de comptage ne peut pas distinguer une nouvelle personne d'une personne déjà vue, entraînant des erreurs de double comptage. Le tracking résout le problème d'association entre détections successives, même en présence d'occlusions, de croisements ou de sorties/entrées du champ de la caméra.

2.2 SORT — Simple Online and Realtime Tracking

Bewley et al. (2016) proposent SORT comme une approche minimaliste et efficace du MOT, combinant deux outils classiques :

- **Filtre de Kalman** : modélise le mouvement de chaque cible comme un état $[x, y, w, h, vx, vy]$ (position, taille, vitesse) et prédit sa position à l'image suivante avant même de recevoir une nouvelle détection.
- **Algorithme hongrois** : résout le problème d'assignation optimale entre les positions prédites et les nouvelles détections, en minimisant une matrice de coût basée sur l'IoU (Intersection over Union) des boîtes.

Limitation principale : SORT utilise uniquement la position géométrique pour l'association. En cas d'occlusion (une personne en cache une autre), le suivi est perdu et un nouvel identifiant est attribué lors du réapparition, causant des erreurs de comptage. Référence : Bewley A. et al., *Simple Online and Realtime Tracking*, ICIP 2016.

2.3 DeepSORT

Wojke et al. (2017) étendent SORT en ajoutant une composante d'apparence visuelle. Un réseau de neurones CNN léger (appelé réseau de réidentification, Re-ID) extrait un vecteur de descripteurs à 128 dimensions à partir de chaque boîte détectée, encodant l'apparence visuelle de la personne (couleur des vêtements, silhouette). L'association combine alors deux métriques :

- **Distance de Mahalanobis** : basée sur la prédiction du filtre de Kalman (position et incertitude).
- **Distance cosinus** : comparaison des embeddings d'apparence via une galerie maintenue pour chaque trajectoire.

Avantage : Robustesse accrue aux occlusions courtes grâce à la mémoire d'apparence.
Inconvénient : Nécessite un réseau Re-ID supplémentaire, augmentant la latence. Peut échouer si deux personnes ont des vêtements similaires. Référence : Wojke N. et al., *Simple Online and Realtime Tracking with a Deep Association Metric*, ICASSP 2017.

2.4 ByteTrack

Zhang et al. (2022) proposent ByteTrack, une méthode qui repense fondamentalement l'utilisation des détections à faible confiance. L'insight clé : les détections à faible score ne sont pas du bruit à ignorer, mais souvent des objets réels partiellement occultés.

Algorithme en deux passes à chaque image :

- **Première association** : associe les trajectoires existantes aux détections à haute confiance (score > seuil haut, ex: 0.6) via IoU + filtre de Kalman.
- **Deuxième association** : pour les trajectoires non appariées, tente une seconde association avec les détections à faible confiance (seuil bas, ex: 0.1-0.6). Ceci récupère les cibles temporairement occultées.
- **Gestion des nouvelles cibles** : seules les détections à haute confiance non appariées créent de nouvelles trajectoires, évitant les faux positifs.

Performances : ByteTrack atteint 80.3 MOTA et 77.3 IDF1 sur MOT17, surpassant DeepSORT sans nécessiter de réseau Re-ID. Vitesse : >30 FPS avec YOLOv8. **Choix recommandé pour ce projet.** Référence : Zhang Y. et al., *ByteTrack: Multi-Object Tracking by Associating Every Detection Box*, ECCV 2022.

2.5 Comparaison des algorithmes de tracking

Composante position	Kalman + Hongrois	Kalman + Hongrois	Kalman + Hongrois
Composante apparence	Aucune	CNN Re-ID 128D	Aucune
Détections faibles	Ignorées	Ignorées	Utilisées (2e passe)
Robustesse occlusion	Faible	Moyenne	Élevée
Vitesse	Très rapide	Modérée	Rapide
ID switches (MOT17)	Élevé	Moyen	Faible
MOTA (MOT17)	~60	~75	~80
Recommandé ici	Non	Possible	✓ Oui

Chapitre 3 — Méthodes de comptage de personnes

3.1 Approche par ligne virtuelle

La méthode de comptage par franchissement de ligne virtuelle est la plus répandue dans les systèmes de comptage à base de tracking. Une ligne (ou zone) est définie manuellement dans l'image. À chaque image, l'algorithme vérifie si le centroïde d'une trajectoire suivie a traversé cette ligne entre l'image précédente et l'image actuelle, en analysant le changement de signe dans la direction perpendiculaire à la ligne.

Avantages :

- Simple à implémenter, faible coût de calcul.
- Comptage bidirectionnel (entrées/sorties) naturel.
- Facile à configurer pour différentes topologies d'espace.

Limites :

- Sensible aux erreurs de tracking (ID switches).
- Problèmes lors de passages simultanés de plusieurs personnes.

3.2 Approche par estimation de densité

Pour les scènes très denses (foules, événements), où le tracking individuel devient impossible, des méthodes basées sur l'estimation de carte de densité ont été développées. Des réseaux comme CSRNet (Li et al., 2018) ou DM-Count apprennent à produire une carte de densité de population à partir de l'image, dont l'intégrale donne directement le nombre de personnes présentes.

Pour ce projet : L'approche par ligne virtuelle combinée au tracking ByteTrack est recommandée. L'estimation de densité n'est pertinente que pour des scènes de plus de 200-300 personnes simultanées, ce qui dépasse le cadre habituel d'une salle de classe ou d'un couloir universitaire.

Chapitre 4 — Datasets & Benchmarks

4.1 COCO — Common Objects in Context

COCO (Lin et al., 2014) est le dataset de référence pour la détection d'objets. Il contient plus de 330 000 images annotées couvrant 80 classes d'objets, dont la classe *person* représente la catégorie la plus fréquente (plus de 250 000 instances). Les modèles YOLO pré-entraînés sur COCO sont directement utilisables pour la détection de personnes dans ce projet, sans annotation supplémentaire.

4.2 MOT Challenge

MOT Challenge est la référence pour évaluer les algorithmes de suivi multi-objets. Il propose plusieurs séquences vidéo annotées :

- **MOT16/MOT17** : scènes piétonnes variées (intérieur/extérieur, jour/nuit, caméras fixes/mobiles), 7 séquences d'entraînement et 7 de test.
- **MOT20** : scènes de foule dense, jusqu'à 246 personnes simultanées par image, pour les cas extrêmes.

4.3 PETS — Performance Evaluation of Tracking and Surveillance

PETS est l'un des premiers benchmarks pour la surveillance vidéo. Il propose des séquences avec des personnes marchant dans des espaces semi-ouverts, avec différents niveaux de densité. Particulièrement utile pour évaluer les systèmes dans des contextes proches de ceux d'un campus universitaire.

4.4 Données propres au projet

Recommandation : En complément des datasets publics, il est fortement conseillé de filmer des séquences vidéo dans les couloirs, amphithéâtres et entrées de bâtiments de votre établissement, afin de constituer un jeu de données représentatif du contexte réel de déploiement. Même 50 à 100 images annotées suffisent pour l'affinage du modèle si les performances de base sont insuffisantes.

Chapitre 5 — Métriques d'évaluation

5.1 Métriques de détection

L'évaluation du modèle de détection repose sur la précision et le rappel, calculés à partir de la matrice de confusion :

- **Précision (Precision)** = $TP / (TP + FP)$: parmi toutes les détections produites, quelle proportion est correcte ?
- **Rappel (Recall)** = $TP / (TP + FN)$: parmi toutes les personnes réelles, quelle proportion a été détectée ?
- **mAP (mean Average Precision)** : moyenne des AP calculées à différents seuils d'IoU. mAP@0.5 et mAP@0.5:0.95 sont les standards COCO.

5.2 Métriques de tracking — MOTA

Le MOTA (Multiple Object Tracking Accuracy), défini par Bernardin & Stiefelhagen (2008), est la métrique de suivi la plus utilisée. Il pénalise simultanément trois types d'erreurs sur l'ensemble de la séquence vidéo :

FN (Faux négatifs)	Personnes manquées par le détecteur	Baisse du MOTA
FP (Faux positifs)	Détections fantômes (bruit)	Baisse du MOTA
IDSW (ID Switches)	Changement d'identifiant sur la même cible	Baisse du MOTA

Formule : $MOTA = 1 - (FN + FP + IDSW) / GT$

5.3 IDF1 — Identity F1 Score

L'IDF1 (Ristani et al., 2016) mesure la capacité du tracker à maintenir des identités cohérentes sur toute la durée d'une trajectoire. Contrairement au MOTA qui est sensible aux faux positifs et négatifs, l'IDF1 se concentre spécifiquement sur la qualité du réidentification : combien de fois la même personne est-elle correctement associée à son identifiant au fil du temps.

Interprétation : Pour un système de comptage, l'IDF1 est particulièrement important car un faible IDF1 signifie beaucoup d'ID Switches, donc des erreurs de double comptage. Un IDF1 > 70% est considéré comme satisfaisant pour les scènes de densité modérée.

5.4 Précision du comptage

En plus des métriques standard de tracking, le système sera évalué sur la précision directe du comptage, mesurée par :

- **MAE (Mean Absolute Error)** : erreur absolue moyenne entre le comptage prédit et le comptage de référence.
- **RMSE (Root Mean Square Error)** : pénalise davantage les grandes erreurs.
- **Taux d'erreur de comptage** = $|N_{\text{prédit}} - N_{\text{réel}}| / N_{\text{réel}} \times 100\%$

Chapitre 6 — Synthèse comparative & choix technologiques

6.1 Architecture retenue

Au terme de cette étude bibliographique, l'architecture suivante est retenue pour le système de comptage intelligent de personnes :

Détection	YOLOv8n / YOLOv8s	Meilleur ratio vitesse/précision, COCO pré-entraîné
Tracking	ByteTrack	SOTA sans Re-ID, robuste aux occlusions
Comptage	Ligne virtuelle	Simple, efficace, bidirectionnel
Interface	Streamlit + OpenCV	Dashboard temps réel, déploiement rapide
Évaluation	MOTA, IDF1, MAE	Standards de la littérature MOT

Pipeline résumé : Flux vidéo → YOLOv8 (détection, ~10ms/image) → ByteTrack (association, <1ms) → Vérification de franchissement de ligne → Mise à jour du compteur → Affichage dashboard (Streamlit/OpenCV).

Chapitre 7 — Références bibliographiques

- [1] Redmon J., Divvala S., Girshick R., Farhadi A. (2016). You Only Look Once: Unified, Real-Time Object Detection. CVPR 2016.
- [2] Ren S., He K., Girshick R., Sun J. (2015). Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. NeurIPS 2015.
- [3] Liu W., Anguelov D., Erhan D. et al. (2016). SSD: Single Shot MultiBox Detector. ECCV 2016.
- [4] Jocher G. et al. (2023). Ultralytics YOLOv8. GitHub repository: <https://github.com/ultralytics/ultralytics>.
- [5] Bewley A., Ge Z., Ott L., Ramos F., Upcroft B. (2016). Simple Online and Realtime Tracking. ICIP 2016.
- [6] Wojke N., Bewley A., Paulus D. (2017). Simple Online and Realtime Tracking with a Deep Association Metric. ICASSP 2017.
- [7] Zhang Y., Sun P., Jiang Y. et al. (2022). ByteTrack: Multi-Object Tracking by Associating Every Detection Box. ECCV 2022.
- [8] Li Y., Zhang X., Chen D. (2018). CSRNet: Dilated Convolutional Neural Networks for Understanding the Highly Congested Scenes. CVPR 2018.
- [9] Lin T.-Y., Maire M., Belongie S. et al. (2014). Microsoft COCO: Common Objects in Context. ECCV 2014.
- [10] Bernardin K., Stiefelwagen R. (2008). Evaluating Multiple Object Tracking Performance: The CLEAR MOT Metrics. JIVP 2008.
- [11] Ristani E., Solera F., Zou R., Cucchiara R., Tomasi C. (2016). Performance Measures and a Data Set for Multi-Target Multi-Camera Tracking. ECCV Workshop 2016.
- [12] Dendorfer P. et al. (2020). MOTChallenge: A Benchmark for Single-Camera Multiple Target Tracking. IJCV 2020.
- [13] Ferryman J., Shahrokni A. (2009). PETS2009: Dataset and Challenge. PETS 2009.